评价器数值验收方案（供审核）

2026-10-19（审核后修订 v4.1，冻结；4.1 只补两处可执行定义）

本轮只做一件事：把 §8.5 的评价函数 $u \mapsto (\mathbb{E}[N], S, J)$ 从 Monte Carlo 估计换成确定性计算，并验收它。验收标准只有三条：和现有 MC 结果一致、网格加密后数值稳定、单次评价耗时可接受。

1. 目的与范围

- 单场景 $d = 20$: $\Delta = \Delta^* = 0.002384694482635785$（全精度），$\sigma = \Delta^*/20$，$\Delta t = 10^{-3}$，$K = 5000$，$T = 5$ s；系统 $G(s) = 2/(1+s)^2$，输入 $u = 1 + \sum_m a_m \cos(\omega_m t + \chi_m)$，$\omega = \{3\sqrt{2}, 3\pi, 12, 12.3\}$，$\sum a_m^2 = 1$。
- 四个固定测试输入（§5），三档网格（§6）。
- 不开新搜索，不复核七个候选，不写任何”误差有严格界”或”全局最优”的结论。这些都在验收通过之后。

MC 实现（`mc83.sod`、`mc83.cfun`、`stage2_common.sod_batch`）保持不动，只作对照。评价器单独实现。

2. 数学依据：参考值的一维密度递推

在 iid 高斯噪声、确定性输出下，send-on-delta 的参考值 r_k 是一条一维 Markov 链，它的密度可以精确递推；$\mathbb{E}[N]$ 和每步的信息权重都是这个密度的积分。递推本身无近似，数值误差只来自网格、尾部截断和 5000 步的传播。

模型。 输出 x_k 确定；观测 $z_k = x_k + e_k$，$e_k \sim \text{iid } N(0, \sigma^2)$；$r_k$ 为第 k 步更新前的参考值。触发规则：$|z_k - r_k| \geq \Delta$ 则发送且 $r_{k+1} = z_k$，否则 $r_{k+1} = r_k$。$k = 1$ 强制发送，所以 $r_2 = z_1$。

记号。

$$g_k(z) = \sigma^{-1}\varphi\Big(\frac{z - x_k}{\sigma}\Big), \qquad \alpha_k(r) = \frac{r - \Delta - x_k}{\sigma}, \qquad \beta_k(r) = \frac{r + \Delta - x_k}{\sigma},$$

$$P_k(r) = \int_{r-\Delta}^{r+\Delta} g_k(z)\, dz = \Phi\big(\beta_k(r)\big) - \Phi\big(\alpha_k(r)\big).$$

$P_k(r)$ 是参考值为 r 时第 k 步不发送的概率。f_k 记 r_k 的密度，F_k 为其分布函数。

递推。

$$f_2 = g_1, \qquad f_{k+1}(s) = f_k(s)\, P_k(s) + g_k(s)\big[\,1 - F_k(s+\Delta) + F_k(s-\Delta)\,\big].$$

第一项：$r_k = s$ 且未发送，参考值留在 s。第二项：发送了，新参考值 $z_k = s$，这要求原参考值 r_k 在 $[s-\Delta, s+\Delta]$ 之外，其概率是 $1 - F_k(s+\Delta) + F_k(s-\Delta)$。

输出量。

$$\mathbb{E}[N] = 1+\sum_{k=2}^{K}\int f_k(r)\,[1-P_k(r)]\,dr, \qquad w_1 = 1, \quad w_k = \int f_k(r)\,c_k(r)\,dr, \qquad J = \sigma^{-2}\sum_{k=1}^{K} w_k\,h_k h_k^{\top}.$$

$c_k(r) = c_{\text{ev}} + c_{\text{no}}$ 是式 (5.10) 的信息系数，只依赖 $\alpha_k(r)$、$\beta_k(r)$，实现沿用已过审的 `mc83.cfun`。$S = \sum_k w_k$。Δm_D、m_E、九个广义特征值 λ_i 按 §8.5 的定义，参考矩阵 J_C 取均匀输入。

质量守恒恒等式。由 Fubini,

$$\int g_k(s)\big[1 - F_k(s+\Delta) + F_k(s-\Delta)\big]\,ds = \int f_k(r)\,[1 - P_k(r)]\,dr,$$

所以 $\int f_{k+1} = \int f_k P_k + \int f_k(1-P_k) = \int f_k$。离散化必须保住这条恒等式，否则质量漂移是必然的，不是偶然误差。这是 §3 诊断和 §4 设计的依据。

3. 现有原型 v0 的问题（从代码读出）

原型 `code/density_recursion.py`（38 行）混用了两套离散规则，质量不守恒是结构性的；同时阈值边界半格不对称。两处都是 $O(h)$ 误差，与”随网格加密单调收敛”一致。本轮目标是解释偏差来源，不是把数调到接近 MC。

v0 的做法。网格步长 $h = \sigma/n$，范围 $[\min x - 8\Delta,\ \max x + 8\Delta]$；$\Delta/h = 20n$ 恰为整数（`sh`）。留下项 $f \cdot P$ 用精确的 $P_k = \texttt{ndtr}(\beta) - \texttt{ndtr}(\alpha)$；触发项的 F_k 用 `cumsum(f)*h`；$F(s+\Delta)$、$F(s-\Delta)$ 用切片 `F[sh:]`、`F[:-sh]` 实现，两端分别用 `F[-1]` 和 0 补齐。没有归一化步骤，每 1000 步打印一次总质量。

两处不一致。

1. 留下项用连续的 P_k，触发项用网格 CDF。§2 的守恒恒等式要求两项用同一套积分规则；现在一精确一网格，恒等式在网格上不成立，观察到的 0.2% 质量漂移（$\sigma/12$）是裸漂移，没有被归一化掩盖。
2. `cumsum` 含当前节点，CDF 偏了半格；切片使 $r = s + \Delta$ 那一格算作不触发、$r = s - \Delta$ 那一格算作触发，边界不对称。

已观察到的偏差（均匀输入，$\sigma/12$，7 s）。$\mathbb{E}[N] = 316.95$（MC 316.87 ± 0.02，差 4 se）；$S = 466.21$（MC 465.96 ± 0.25）；$\log\det J = 197.2023$（MC 197.1966 ± 0.003）；J_{rec} 对 J_{MC} 的广义特征值 0.997–1.004。

不变的部分。触发约定与 `mc83.sod` 一致：$|z - r| \geq \Delta$ 触发、$k = 1$ 强制发送、参考值取含噪声的 z。$\mathbb{E}[N]$ 用更新前的 f_k 和 $(1 - P_k)$ 累加，这一步本身没有问题。

4. 三个离散化版本 v0 / A / B

把递推写成网格上的离散 Markov 链：留下项和触发项用同一个离散核和同一个”不触发权重”，转移矩阵按构造就是随机矩阵，质量守恒到舍入，密度不可能为负。A 和 B 只差阈值端点的处理；v0 另外还混用了连续 P 和离散 CDF，公共代码里必须保留这一区别。各自的收敛阶是预测，由 §6 测出来。

公共设定。节点 $z_i = z_0 + ih$，$h = \sigma/n$，$n \in \{6, 12, 24\}$；$M = \Delta/h = 20n$ 为整数。用质量而不是密度：$m_{k,i} = f_k(z_i)\,h$。离散测量核

$$\hat{g}_{k,j} = \frac{g_k(z_j)}{\sum_{j'} g_k(z_{j'})}, \qquad \sum_j \hat{g}_{k,j} = 1.$$

归一化前的和 $\sum_j g_k(z_j)\,h$（核的截断质量）和归一化因子每步记录。$h \leq \sigma/6$ 时高斯的节点求和误差是

指数小的，预计因子与 1 的差 $< 10^{-12}$，但要记，不要假定。

不触发权重。 $\omega_{ij} \in [0,1]$ 表示参考值在节点 i、测量落在节点 j 时算作不触发的份额。则

$$\hat{P}_{k,i} = \sum_j \hat{g}_{k,j}\,\omega_{ij}, \qquad m_{k+1,j} = m_{k,j}\,\hat{P}_{k,j} + \hat{g}_{k,j} \sum_i m_{k,i}\,(1-\omega_{ij}).$$

初始化 $m_{2,j} = \hat{g}_{1,j}$。对 j 求和：$\sum_j m_{k+1,j} = \sum_j m_{k,j}\hat{P}_{k,j} + \sum_i m_{k,i}(1-\hat{P}_{k,i}) = \sum_i m_{k,i}$。守恒是恒等式，不依赖 ω 的具体取法；$m \geq 0$ 由构造保证。

三个版本。

版本	ω_{ij}	守恒	端点误差	预测收敛阶
v0	现有代码（精确 P + 网格 CDF，切片不对称）	否（0.2% @ $\sigma/12$）	$O(h)$，不对称	1
A	1 若 $\lvert i-j\rvert < M$，否则 0	是	$-\frac{h}{2}[g(r-\Delta) + g(r+\Delta)] + O(h^2)$，对称	1
B	1 若 $\lvert i-j\rvert < M$；$\frac{1}{2}$ 若 $\lvert i-j\rvert = M$；否则 0	是	预计 $O(h^2)$（梯形端点）	2

A 的一阶误差有单步算例：标准正态测量、$\Delta = 20$、$r = -20$，真值 0.5，$h = 1/12$ 时得 0.483377（审核方复算），误差随 h 减半；审核方另用非对称算例测得单步观测阶 $p_A = 1.011$、$p_B = 2.002$。B 的半权是对连续阈值积分 $\int_{r-\Delta}^{r+\Delta} g$ 的梯形求积规则，不是修改触发模型（物理触发仍是逐点 $\geq \Delta$）；每个测量节点的权重仍精确加到 1，守恒不受影响。单步二阶不等于 5000 步后所有输出都二阶，由 §6 的三档网格判定。

输出量的离散形式。 每个版本内部一致：

$$\mathbb{E}[N] = 1 + \sum_{k\geq 2} \sum_i m_{k,i}\,(1-\hat{P}_{k,i}), \qquad w_k = \sum_i m_{k,i}\,c_k(z_i).$$

c_k 是 r 的光滑函数，对给定的 m_k 节点求值是 $O(h^2)$ 的求积；但 m_k 本身带有递推累积的误差（A 为一阶），总误差阶由后者决定。作为零成本诊断，同时记录用精确 P_k 算的 $\mathbb{E}[N]$：两者之差只度量同一 m_k 下概率公式的差异，不含此前累积的分布偏差。

实现。 $\sum_{|i-j|<M}$ 是滑动窗口和，用前缀和实现，每步 $O(G)$，G 为节点数。耗时与 v0 同量级。三个版本在同一个文件里用开关切换，公共代码只写一份。

5. 四个测试输入

四个输入覆盖三种情况：参考点、预算内最优、强 E 约束下的候选，以及一个 $\mathbb{E}[N]$ 明显偏离 316 的输入。前三个的 $\mathbb{E}[N]$ 都在 316 附近，测不出评价器在发送数偏离时是否仍准，所以加第四个。

编号	输入	来源	已知 MC 值
U	UNIF：$a_m = 1/2$，$\chi_m = 0$	§8.3	$\mathbb{E}[N]$ 316.87 ± 0.02，S 465.96，$\log\det$ 197.1966 ± 0.003

编号	输入	来源	已知 MC 值
D	NM-none-P5514，$p = (0.252, 0.251, 0.252, 0.245)$	`code/amp_nm_P5514.json`，阶段2 日志行	Δm_D $+0.697 \pm 0.004$，m_E 0.045
E	$m_E \geq 0.7$ 的代表候选	阶段3 日志行	Δm_D $+0.262$
N	无预算最优	阶段3 日志行	Δm_D $+2.10 \pm 0.01$，多发 107 次

四个输入的完整幅值 a_m、相位 χ_m、来源日志行号写进 `config.json` 并随预测文件一起提交；此后不改。E 和 N 的具体 ID 由 Claude Code 从阶段3 日志取，写明取的是哪一行。

冻结的约定（与 `mc83.py` 一致）。 时间索引 $t_k = k\,\Delta t$，$k = 1, \ldots, K$（首点 $t_1 = \Delta t$，末点 $t_K = T$）；稳态输出 $x_k = G(0) \cdot 1 + \sum_m a_m |G(j\omega_m)| \cos(\omega_m t_k + \chi_m + \arg G(j\omega_m))$；回归向量 h_k 的参数顺序为 $[G(0),\ \mathrm{Re}\, G(j\omega_1),\ \mathrm{Im}\, G(j\omega_1), \ldots]$，列为 $[1,\ a_m \cos\psi_{k,m},\ -a_m \sin\psi_{k,m}]$，$\psi_{k,m} = \omega_m t_k + \chi_m$。递推与 MC 共用同一个 x_k、h_k 数组，避免一拍偏差。

m_E 的定义（§8.5）。 $m_E^{(C)} = \lambda_{\min}(J_u, J_C)$，即 $J_u v = \lambda J_C v$ 的最小广义特征值；它就是候选对 U 的九个 λ_i 中最小的一个，不是另一个量。解释：两个矩阵正定时

$$\frac{1}{m_E} = \max_{a \neq 0} \frac{a^\top J_u^{-1} a}{a^\top J_C^{-1} a},$$

即所有参数线性组合中 CRLB 方差相对均匀参考的最大倍数；达到该比值的组合系数可取 $a = J_C v$（不是 v 本身：由 $J_u^{-1} a = v/\lambda$、$J_C^{-1} a = v$ 得比值 $1/\lambda$）。这个最坏方向随候选变化，不是对所有候选预先固定的同一方向。交接文档”已知的坑”里”某固定线性组合”一句按此理解，不是指 v。

6. 网格、尾部与收敛研究

三个版本 × 四个输入 × 三档网格，共 36 次评价；每次记录同一组量，收敛看最细两档，收敛阶只作诊断。

每次评价记录。 $\mathbb{E}[N]$（两种 P 各一个）、S、完整 J（存 `.npy`）、$\log\det J$、$\Delta m_D^{(C)}$（对同版本同网格的 U）、九个广义特征值 λ_i（$J(u)$ 对 J_C，$m_E = \lambda_1$）、每步质量 $\sum_i m_{k,i}$ 的最大偏离、核归一化因子的最大偏离、$\min m$、G、稳态耗时（去掉导入和 JIT）。每个数在日志里对应一行。

数学不变量（每次评价都查）。 $0 \leq c_k(r) \leq 1$；$1 \leq S \leq K$；$0 \preceq J \preceq \sigma^{-2} \sum_k h_k h_k^\top$（后者是全测量信息矩阵，差应半正定）。这三条不依赖 MC，能发现 `cfun` 的尾部消减、$0/0$ 或索引错误；递推与 MC 共用 `cfun`，互相一致不能排除共享的错误。

网格。 $n = 6, 12, 24$，即 $h = \sigma/6, \sigma/12, \sigma/24$。记相邻两档之差 $d_1 = Q(6) - Q(12)$、$d_2 = Q(12) - Q(24)$，以及

$$p_{\mathrm{obs}} = \log_2 \left| \frac{d_1}{d_2} \right|.$$

对绝对量（$\log\det J$、$\mathbb{E}[N]$、S）和相对量（Δm_D、λ_i）分别算：候选与参考的误差可能相消，使差值看起来比绝对量高一阶。p_{obs} 只有在差值远大于舍入、尾部影响可忽略时才能解释为收敛阶；三档一个比值是诊断证据，不是证明。U 的相对量（$\Delta m_D(U) = 0$、$m_E(U) = 1$）恒等，差值为零，p_{obs} 标”不适用”，不据此触发任何动作。若某输入某绝对量的 p_{obs} 偏离该版本的预测阶 $p_0 \in \{1, 2\}$ 超过 0.5，或相邻差值变号，对该输入加 $n = 48$，不全局加，也不用该 p_{obs} 做外推。“舍入量级”的可执行定义：$|d_2| \leq 10^{-8} \max(1, |Q(24)|)$。$d_2$ 在舍入量级只说明阶数不可辨识：工程稳定性条件已满足时记”阶数不可判定”，不单独触发加密。$n = 48$ 只能由本段或 §7 的不通过触发，触发后执行下面的网格切换规则。

网格切换规则。 若某输入因上述原因或 §7 的不通过转为 $n = 48$ 验收，该输入的全部规则同步切换：稳

定性比较改为 24/48；白化矩阵 W 改用 J_{48}；候选对 U 的配对量需要 U 的 $n = 48$ 结果，补算，不沿用 U 的 $n = 24$；报告写实际受验的网格。

尾部。 在 $n = 12$ 下把范围裕量从 8Δ 扩到 16Δ，记每个量的变化。裕量 $8\Delta = 160\sigma$，预计变化 $< 10^{-8}$；这一步是确认，不是调参。

工程目标。 版本 B 在最细两档上：$|\Delta m_D(12) - \Delta m_D(24)| \le 0.002$ nat；$|\log\det(12) - \log\det(24)| \le 0.005$ nat；$|\mathbb{E}[N](12) - \mathbb{E}[N](24)| \le 0.02$；$|m_E(12) - m_E(24)| \le 0.002$；矩阵整体 $\|J_{24}^{-1/2} J_{12} J_{24}^{-1/2} - I\|_2 \le 0.005$。只控制 $\log\det$ 不能保证最弱方向稳定，而后续恰好用 m_E 判约束，所以后两条不能省。这是数值稳定性标准，为最终 0.02 nat 的分辨目标留余量；它不是误差上界，报告里不把它写成上界。

耗时。 跑前冻结硬件（CPU 型号、核数）；实现方式已定：A、B 用 numba，v0 保持原型的 numpy（它只作回归对照）；通过线：版本 B、$n = 24$、单次评价稳态耗时 ≤ 60 s（numpy）或 ≤ 15 s（numba）。超线时耗时项不通过；数值准确性验证照常完成，报告分开写”数值验收通过、耗时未通过”，不宣称全部验收通过。无论是否超线，报告都给出搜索一轮（约 3000 次评价）的折算总时长。

7. 与 MC 的对照

MC 只能把评价器核到它自身分辨率的水平（$\log\det$ 约 0.01 nat，$\mathbb{E}[N]$ 约 0.05 次），所以它验的是”在 MC 分辨率下未发现差异”，不是”无偏”；0.002 nat 的稳定性只能由 §6 的网格研究给出。两个结论分开写。

MC 参考。 四个输入用同一个新种子（例如 20261019）、$R = 10000$、公共随机数配对，$B = 20$ 批 $\times$ 500 条轨迹。**点估计一律由全部 10000 条轨迹汇总的权重 $\bar{w}_k$ 得到的矩阵计算**（$\bar{J} = \sigma^{-2} \sum_k \bar{w}_k h_k h_k^\top$，再取 $\log\det$、广义特征值等），不是各批指标的平均；批只用来算标准误，$\widehat{\mathrm{se}} = s_{\mathrm{batch}}/\sqrt{20}$。报告里的 $\pm$ 一律是标准误，不是置信区间。U 的旧结果（seed 20261006，$R = 10000$，`wk_d20_10000.npy`）另作一致性检查：两次独立 MC 的差用 $\mathrm{se}_{\mathrm{diff}} = \sqrt{\mathrm{se}_{\mathrm{old}}^2 + \mathrm{se}_{\mathrm{new}}^2}$，$\mathrm{se}_{\mathrm{old}}$ 取 §8.3 原始日志（$\mathbb{E}[N]$ 0.02、$\log\det$ 0.003）；找不到就只报原始差值，不把”以新 se 为单位的差”称为检验统计量。相对量（Δm_D、m_E）在每批内用同批的候选矩阵和 U 矩阵算配对差，再取批间标准误；绝对 $\log\det$ 的 0.003 se 不能推出配对 Δm_D 的分辨率，后者实测。

非线性偏差诊断。 记 $D = \log\det \bar{J} - \frac{1}{B}\sum_b \log\det \hat{J}_b$（凹性保证 $D \ge 0$）。它主要反映每批 500 条的非线性效应；二阶近似下汇总点估计的偏差约为 $-D/(B-1) = -D/19$。记录 D，以 $-D/19$ 估计二阶偏差，与 se 比较，只作诊断；$D/19 \ge \widehat{\mathrm{se}}$ 时再查汇总估计的偏差，不直接判评价器失败。该换算是近似，不写成误差界。

矩阵的直接比较。 只比 $\log\det$、S 和相对 U 的特征值不能验收完整 J：两个矩阵可以迹、行列式、特征值全同而信息方向不同。对每个输入取固定白化 $W = J_{\mathrm{rec}}^{-1/2}$（$J_{\mathrm{rec}}$ 为版本 B、$n = 24$，不依赖本轮 MC 数据），对每批

$$D_b = W \hat{J}_{\mathrm{MC},b} W^\top - I.$$

D_b 的每个元素是批矩阵的线性函数，原假设 $J_{\mathrm{rec}} = J_{\mathrm{true}}$ 下 $\mathbb{E}[D_{b,ij}] = 0$，批均值近似正态，可用 t_{19} 校准。检验对象是上三角 45 个元素的批均值及其标准误，另加迹的均值 $\mathrm{tr}(\bar{D})/9$ 作为整体尺度偏差的单一标量。九个广义特征值 $\lambda_i(J_{\mathrm{rec}}, \bar{J}_{\mathrm{MC}})$ 只展示不检验：原假设下它们是九重根 1，加噪声后排序特征值向两侧展开，不是以 1 为中心的近似正态标量。

比较清单（跑前冻结，正式 199 项）。 每个输入 49 项：$\mathbb{E}[N]$、S、$\log\det J$、$\mathrm{tr}(\bar{D})/9$、$\bar{D}$ 的 45 个上三角元素；四个输入 196 项。三个候选（D、E、N）各 1 项：对 U 的配对 Δm_D；共 3 项。正式清单 $196 + 3 = 199$ 项。m_E 不纳入正式标量 t 检验：它是最小广义特征值，其标量正态近似需要特征值间隙相对整个矩阵扰动足够大，经验筛查保证不了这一点；m_E 保留展示（含配对 se 和 $\lambda_2 - \lambda_1$）并做 §6 的网格稳定性验收，完整矩阵的一致性由白化元素检验承担。阈值仍按 202 项计算（略保守）；报告写”199 项正式比较，阈值按 202 项校正”，不把未检验的 m_E 写成统计检验通过。U 对自己的相对量恒为 0 和 1，无随机误差，不进清单，只作恒等式检查。候选对 U 的九个 λ_i 是派生量，只展示。评价器一侧取版本 B、$n = 24$；v0 和 A 的对照只进附表。

判定。 每项报标准化差 $z = (\text{rec} - \text{MC})/\widehat{\text{se}}$（白化元素的 rec 值为 0）。标准误来自 20 批，自由度 19，按近似 t_{19} 校准（批均值正态只是近似，$\log\det$、Δm_D 等非线性指标的校准也是近似）；199 项正式比较，单项阈值按 202 项双侧 Bonferroni 校正

$$t_{19,\,1-0.05/(2\times 202)} = 4.496.$$

同时报符号模式作辅助诊断：四个输入的 $\mathrm{tr}(\bar{D})/9$ 是否同号、各输入 $\bar{D}$ 对角元的同号个数；指标相关，符号计数不按独立检验解释，只用于提示系统性尺度偏差。Bonferroni 不要求指标独立，但要求单项校准成立——这正是改用白化元素而不是排序特征值的原因。

措辞规则。 通过写”在当前 MC 分辨率下未发现显著差异”；不写”验证了无偏”。

不通过时。 Richardson 外推只作诊断：在 $Q(h) = Q_* + Ch^p + o(h^p)$ 得到三档数据支持时，用最细两档和 p_{obs} 外推，看外推值是否落回阈值内。若 B/$n = 24$ 不通过而外推值通过，结论是”该网格的离散误差仍不可忽略”，处理是加密到 $n = 48$ 重验，不是判 B/$n = 24$ 通过；也可以把经独立验证的外推方案正式定义为评价器，但那是另一轮。外推值仍超阈值，再按顺序查尾部、触发约定（$\geq$ 还是 $>$、首步强制发送、参考值取噪声后的 z）、MC 自身实现。预算或 m_E 边界附近的候选若加密后仍判不定，标”未定”，不归类。任何情况下不调参数去贴 MC，不启动新搜索。

8. 跑前预测

按工作规则 1，下面的预测写进 `predictions.md` 并在跑前提交，跑后逐条对照，错的也报。

编号	预测	判定方式
P1	v0 质量漂移约 0.2% @ $\sigma/12$，随 h 线性减小；A、B 的漂移 $\leq 10^{-12}$（5000 步舍入量级）	每步质量日志
P2	收敛阶：v0 ≈ 1，A ≈ 1，B ≈ 2（绝对 $\log\det$ 与 $\mathbb{E}[N]$ 上）	p_{obs}
P3	A 的 $\mathbb{E}[N]$ 偏高于 MC，偏差随 h 减半；$\sigma/12$ 时与 v0 的 $+0.08$ 同量级	$\mathbb{E}[N]$ 表
P4	B 在 $n = 24$ 上，U 的 $\mathbb{E}[N]$、$\log\det$ 落在 MC 2 se 内；199 项中 $\lvert z\rvert > 4.496$ 的为 0	§7 判定表
P5	用精确 P 与用 $\hat{P}$ 算的 $\mathbb{E}[N]$ 之差：A 为 $O(h)$，B 为 $O(h^2)$，与 P2 一致	零成本诊断
P6	尾部裕量 $8\Delta \to 16\Delta$，所有量变化 $< 10^{-8}$	尾部表
P7	稳态耗时 $n = 24 \approx 2\times$ $n = 12$；numpy 实现 $n = 12$ 约 7 s，numba 可再快 3–5 倍	耗时表
P8	输入 N（无预算）的 $\mathbb{E}[N]$ 在 MC 的 2 se 内，与预算内三个输入无系统差别	$\mathbb{E}[N]$ 表
P9	Δm_D 的网格差 d_2 小于绝对 $\log\det$ 的 d_2（误差相消），但两者的 p_{obs} 都接近 2	收敛表

编号	预测	判定方式
P10	四个输入的 $\mathrm{tr}(\bar{D})/9$ 的 $\lvert z\rvert < 2$，且四个不全同号；45 个上三角元素没有系统性的同号块	§7 判定表
P11	非线性偏差：$D > 0$，且 $-D/19$ 的绝对值小于 $\log\det$ 的 se（0.003 量级）	诊断表
P12	三条数学不变量在 36 次评价中全部成立，c_k 在尾部（$\lvert\alpha\rvert, \lvert\beta\rvert > 30$）无 NaN、无负值	不变量日志

预测只写方向和量级，不写精确数字；跑完后在报告里逐条标”对/错/部分对”。

9. 验收标准（预注册）

三类标准加耗时线彼此独立，各自通过或不通过，不合并成一个总分。三类数值标准都通过即”数值验收通过”；耗时单独报告；四项都通过才写”评价器验收通过”，之后才用它复核候选。信息系数 `cfun` 已在 §8.4 的测试设置下获得 ML 仿真交叉验证（4000 次，标准差比 0.986–1.012）；本轮另检查评价器中的数值不变量和尾部计算，两者互补，都不单独证明 `cfun` 在所有 (α, β) 上正确。

类别	标准	通过条件
离散实现	非负性	A、B 所有步 $\min m \geq 0$；v0 只记录，不作通过项
离散实现	质量守恒	A、B 每步 $\lvert\sum m - 1\rvert \leq 10^{-10}$，并报实际最大漂移是否在舍入量级
离散实现	核截断	归一化前核质量与 1 的差 $\leq 10^{-12}$，因子记录
离散实现	触发约定	与 `mc83.sod` 逐条一致（$\geq \Delta$、首步强制、参考值取 z），写进 README
离散实现	数学不变量	$0 \leq c_k \leq 1$、$1 \leq S \leq K$、$0 \preceq J \preceq \sigma^{-2}\sum h_k h_k^\top$，A、B 的 24 次评价全部成立；v0 的 12 次只记录
数值收敛	最细两档	版本 B：$\lvert\Delta m_D(12) - \Delta m_D(24)\rvert \leq 0.002$，$\lvert\log\det(12) - \log\det(24)\rvert \leq 0.005$，$\lvert\mathbb{E}[N](12) - \mathbb{E}[N](24)\rvert \leq 0.02$，$\lvert m_E(12) - m_E(24)\rvert \leq 0.002$，$\lVert J_{24}^{-1/2} J_{12} J_{24}^{-1/2} - I\rVert_2 \leq 0.005$，四个输入都满足
数值收敛	尾部	$8\Delta \to 16\Delta$ 所有量变化 $\leq 10^{-6}$
数值收敛	收敛阶	报 p_{obs}，不设通过线；与 P2 对照

类别	标准	通过条件
MC 一致性	冻结清单	199 项（§7；m_E 只展示），版本 B、$n = 24$ 对 MC（$R = 10000$，新种子，20 批配对）；点估计来自汇总矩阵
MC 一致性	阈值	199 项全部 $\lvert z\rvert \le t_{19,\,1-0.05/404} = 4.496$（按 202 项校正的近似 t_{19} Bonferroni）
MC 一致性	符号诊断	报 $\mathrm{tr}(\bar{D})/9$ 的符号与各输入对角元同号数；四个输入 $\mathrm{tr}(\bar{D})/9$ 全同号且 $\lvert z\rvert > 2$ 时标”可疑尺度偏差”，需解释后才算通过
MC 一致性	非线性诊断	报 D 与 $-D/19$；不设通过线
耗时	通过线	版本 B、受验网格，稳态单次 ≤ 60 s（numpy）或 ≤ 15 s（numba），硬件与实现跑前冻结；不通过时单独报告，不影响数值验收结论

不通过的处理见 §7 末段。通过后的措辞固定为：“评价器在四个测试输入上与 MC 在其分辨率下未发现显著差异（199 项正式比较，阈值按 202 项校正的近似 t_{19} Bonferroni）；网格 $\sigma/12$ 与 $\sigma/24$ 之间 Δm_D 的变化不超过 0.002 nat、m_E 不超过 0.002。”若某输入按 §6 切换到 $n = 48$，措辞中的网格改为实际受验的 24/48，并注明是哪个输入。

10. 产出与不写的内容

一轮交付一个可审核结果：代码、配置、日志、矩阵、三张表、一份只回答三个问题的报告。

文件（仓库 `code_8_3_stage2/stage2_pkg/evaluator/`）。

- `density_recursion_v1.py`：三个版本一个开关；公共代码一份。
- `config.json`：四个输入的 a_m、χ_m、来源行号；网格 n；裕量；MC 种子与 R。
- `predictions.md`：§8 的十二条，跑前提交，报告引用其 commit hash。本方案 v4 为冻结版，实现阶段不再扩充。
- `run_all.py` 与日志：36 次评价 + 4 次 MC，每个数一行。
- `results/`：J 矩阵 `.npy`、每步质量序列、汇总 JSON。
- `report_evaluator_CN.md`：表 1 版本 × 输入 × 网格；表 2 对 MC 的 z 与符号；表 3 预测对照（含错的）。
- `requirements.txt` 加 numba；不再只在 README 备注。

报告只回答。 递推评价器与原模型是否一致；在测试输入上数值稳定到什么程度；一次评价多久。

报告不写。 “误差已严格有界”、“可证明全局最优”、投影梯度等过程信息、未跑的仿真。

审核。 交付后打包给审核 AI（参照 `review_8_5_stage2.zip` 的 `REVIEW_GUIDE.md` 格式），审核意见逐条复算后再改。

11. 通过后的下一步（不在本轮）

验收通过后，评价器成为 §8.5 剩余工作的唯一评价函数，MC 只保留给 §8.4 的估计器核验。顺序：

1. 用评价器复核七个最终候选的 Δm_D、m_E 和可行性（$\mathbb{E}[N] \le 316$）。确定性评价消除了 MC 随机波动，没有消除离散偏差：$\widehat{\mathbb{E}[N]} = 315.999$ 而数值误差尺度仍在 0.01 时，不能确认真实值满足约

束。“边界附近未定”规则保留；报告加密后的数值判断，不把”确定性”当作可行性的保证。

2. 搜索换评价器重跑一遍（Nelder–Mead，现有协议，$\lambda_0 \in \{\text{无}, 0.3, 0.5, 0.7\}$），比较最优点与 MC 版本。
3. 在多正弦族内最大化 $S(u)$，约束 $\mathbb{E}[N] \le 316$。搜到的 $S_{\text{found}} \le S^* = \sup_{u \in \mathcal{F}} S(u)$ 是最大值的下界，代入路 1 的 U_B 得到的只是”已评估候选集上的估算值”，不是族上的上界；族上的上界需要另外的论证（§2 之后的闭环 MDP 界或别的）。
4. 闭环 MDP 上界（对所有轨迹严格，预计松数 nat）作为对照放进报告。

这四项各自有预测文件和审核，不并入本轮。